



Министерство науки и высшего образования Российской Федерации
Федеральное государственное бюджетное образовательное учреждение
высшего образования
«Московский государственный технический университет
имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ _____ Информатика и системы управления _____

КАФЕДРА _____ Программное обеспечение ЭВМ и информационные технологии _____

ТИПЫ И СТРУКТУРЫ ДАННЫХ
ОТЧЕТ ПО ЛАБОРАТОРНОЙ РАБОТЕ № 6
“Деревья, хэш-таблицы”
ВАРИАНТ 0

Студент _____ Гурова Наталия Алексеевна _____
фамилия, имя, отчество

Группа _____ ИУ7-34Б _____

Выполнил _____ Гурова Н.А. _____
подпись, дата *фамилия, и.о.*

Принял _____ Силантьева А.В. _____
подпись, дата *фамилия, и.о.*

Цель работы

Цель работы – построить дерево, вывести его на экран в виде дерева, реализовать основные операции работы с деревом: обход дерева, включение, исключение и поиск узлов, сбалансировать дерево, сравнить эффективность алгоритмов сортировки и поиска в зависимости от высоты деревьев и степени их ветвления; построить хеш-таблицу и вывести ее на экран, устранить коллизии, если они достигли указанного предела, выбрав другую хеш-функцию и реструктуризировав таблицу; сравнить эффективность поиска в сбалансированных деревьях, в двоичных деревьях поиска (ДДП), в хеш-таблицах и в файлах. Сравнить эффективность реструктуризации таблицы для устранения коллизий и поиска в ней с эффективностью поиска в исходной таблице.

Задание

В текстовом файле содержатся целые числа. Построить ДДП из чисел файла. Вывести его на экран в виде дерева. Сбалансировать полученное дерево и вывести его на экран. Построить хеш-таблицу из чисел файла. Использовать метод цепочек для устранения коллизий. Осуществить поиск введенного целого числа в ДДП, в сбалансированном дереве, в хеш-таблице и в файле. Сравнить время поиска, объем памяти и количество сравнений при использовании различных (4-х) структур данных. Если количество сравнений в хеш-таблице больше указанного (вводить), то произвести реструктуризацию таблицы, выбрав другую функцию.

Входные данные

- Для пунктов меню 0, 1, 2, 3, 4, 5, 6 вводится данный пункт в виде целого
- Для пункта 2 вводится также целое число, которое нужно вставить в дерево и хэш таблицу
- Для пункта 3 вводится также целое число, которое требуется найти
- Для пункта 5 вводится также целое число, обозначающее максимальное среднее количество сравнений для хеш-таблицы
- Для пункта 6 вводятся также параметры исследования памяти и

эффективности (количество измерений, количество элементов для каждого измерения)

Выходные данные

- Результат выполнения определенной команды:
 1. Сообщение о том, что данные успешно считаны из файла, либо о том, что в процессе чтения произошла ошибка
 2. Сообщение о том, что вставка элемента произошла успешно, либо о том, что в процессе произошла ошибка
 3. Интерфейс ввода числа, информация об успешности его нахождения, в также количество сравнений, произведенных в каждой структуре данных.
 4. Двоичное дерево, ab1 дерево и хэш-таблица
 5. Информация о текущем среднем количестве сравнений. Интерфейс ввода числа, информация об успешности реструктуризации таблицы
 6. Отчет о количестве запрашиваемой памяти, эффективности и количестве сравнений.

Возможности программы

- 0 – выход из программы
- 1 - Загрузить данные из файла
- 2 – Выставить элемент
- 3 – Найти элемент
- 4 – Печать
- 5 – Реструктуризация таблицы
- 6 – Проведение исследования

Способ обращения к программе

Программа может быть вызвана через консоль с помощью команды app.exe

Аварийные ситуации

- Некорректный ввод номера команды (введено не число)
- Некорректные данные в файле
- Некорректный ввод нового количества сравнений
- Некорректный ввод нового элемента (повтор)

Описание алгоритма

1. Выводится меню данной программы.
2. Пользователь вводит номер команды из предложенного меню.
3. Пока пользователь не введет 0 (выход из программы), ему будет предложено вводить номера команд и выполнять действия по выбору.
4. Для реструктуризации хеш-таблицы применяется инкрементация хеш-константы в цикле до тех пор, пока среднее количество сравнений не станет меньше указанного предела.

Структуры данных

```
// Обычное дерево
typedef int tree_data_t;

typedef struct tree_node tree_node_t;
struct tree_node
{
    tree_data_t data;           // данные узла
    struct tree_node *left;     // левое поддерево
    struct tree_node *right;    // правое поддерево
};

// ABL-дерево
typedef struct abl_node abl_node_t;
struct abl_node
{
    int data;                   // данные узла
    int height;                 // высота узла
    abl_node_t* left;           // левое поддерево
    abl_node_t* right;          // правое поддерево
};

//элемент хеш-таблицы
typedef int node_data_t;
typedef struct node_t
{
    struct node_t *next;        // указатель на следующий элемент
    bool is_data_fill;          // флаг, заполнена ли ячейка
    node_data_t data;           // данные
} node_t;

//структура хеш-таблицы
typedef node_t* list_node_t;
typedef struct
{
    int count_indexes;           // количество индексов
    int count_collision;         // количество коллизий
    list_node_t *array;          // массив данных
    int (*hash_func)(int n, ...); // хэш-функция (n - кол-во параметров)
} hash_table_t;
```

Оценка эффективности

Время поиска элемента (в тактах процессора, 5000 итераций):

FIND ELEM					
	TREE	ABL TREE	HASH TABLE	FILE	
100	86	52	19	24838	
500	661	546	168	149478	
1000	3927	1344	315	530523	
1500	2583	1102	472	709159	

Память (в байтах):

MEMORY					
	TREE	ABL TREE	HASH TABLE	FILE	
100	1824	1824	1580	337	
500	54960	54960	48340	10750	
1000	300000	300000	260920	43780	
1500	874800	874800	760860	107430	

Количество сравнений:

COUNT CMP					
	TREE	ABL TREE	HASH TABLE	FILE	
100	7	7	2	70	
500	40	6	1	119	
1000	170	11	1	752	
1500	180	11	1	1414	

Вывод

Основным преимуществом файла является то, что файл занимает меньше памяти (примерно в 5 раз).

Основным преимуществом хэш-таблицы является то, что поиск элемента в ней занимает меньше времени (если хэш-функция подобрана хорошо) (в 3 и более раза).

Основным преимуществом деревьев является возможная высокая эффективность реализации основанных на нем алгоритмов поиска и сортировки.

Между сбалансированным и несбалансированным лучше выбирать сбалансированное дерево. Хотя это и увеличит сложность обработки, но даст возможность сделать поиск более эффективным за счет уменьшения высоты

дерева и, следовательно, количества сравнений. (в 6 и более раз)

Из приведенной выше оценки эффективности можно сделать вывод, что лучше всего и по памяти, и по времени работает хеш-таблица. Поиск элемента в хэш-таблице занимает меньше времени, чем в дереве.

Контрольные вопросы

1. Что такое дерево?

Дерево – это нелинейная структура данных, используемая для представления иерархических связей, имеющих отношение «один ко многим». Деревом базовым типом T определяется рекурсивно либо как пустая структура (пустое дерево), либо как узел типа T с конечным числом древовидных структур этого же типа, называемых поддеревьями.

2. Как выделяется память под представление деревьев?

Способ выделения памяти под деревья определяется способом их представления в программе. С помощью матрицы или списка может быть реализована таблица связей с предками или связный список сыновей. Целесообразно использовать списки для упрощенной работы с данными, когда

элементы требуется добавлять и удалять, т. е. выделять память под каждый элемент отдельно. При реализации матрицей память выделяется статически.

3. Какие стандартные операции возможны над деревьями?

Основные операции с деревьями: обход дерева, поиск по дереву, включение в дерево, исключение из дерева. Обход вершин дерева можно осуществить следующим образом:

- сверху вниз (префиксный обход)
- слева направо (инфиксный обход)
- снизу вверх (постфиксный обход)

4. Что такое дерево двоичного поиска?

Дерево двоичного поиска – это такое дерево, в котором все левые потомки моложе предка, а все правые – старше.

Это свойство называется характеристическим свойством дерева двоичного поиска и выполняется для любого узла, включая корень. С учетом этого свойства поиск узла в двоичном дереве поиска можно осуществить, двигаясь от корня в левое или правое поддерево в зависимости от значения ключа поддерева.

5. Чем отличается идеально сбалансированное дерево от AVL дерева?

Идеально сбалансированное дерево: при добавлении узлов в дерево мы будем их равномерно располагать слева и справа, и получится дерево, у которого число вершин в левом и правом поддеревьях отличается не более, чем на единицу.

AVL-дерево: двоичное дерево называется сбалансированным, если у каждого узла дерева высота двух поддеревьев отличается не более чем на единицу.

6. Чем отличается поиск в AVL-дереве от поиска в дереве двоичного поиска?

Временная сложность поиска элемента в AVL дереве – $O(\log_2 n)$

Временная сложность поиска элемента в дереве двоичного поиска – от

$O(\log_2 n)$ до $O(n)$.

7. Что такое хеш-таблица, каков принцип ее построения?

Массив, заполненный в порядке, определенным хеш-функцией, называется хеш-таблицей. Функцию, по которой можно вычислить этот индекс, называется хеш-функцией. Принято считать, что хорошей является такая функция, которая удовлетворяет следующим условиям:

- функция должна быть простой с вычислительной точки зрения;
- функция должна распределять ключи в хеш-таблице наиболее равномерно.
- функция должна минимизировать число коллизий

8. Что такое коллизии? Каковы методы их устранения.

Коллизия - ситуация, когда разным ключам соответствует одно значение хеш-функции, то есть, когда $h(K1)=h(K2)$, в то время как $K1 \neq K2$.

Первый метод – внешнее(открытое) хеширование (метод цепочек). В случае, когда элемент таблицы с индексом, который вернула хеш-функция, уже занят, к нему присоединяется связный список. Таким образом, если для нескольких различных значений ключа возвращается одинаковое значение хеш-функции, то по этому адресу находится указатель на связанный список, который содержит все значения.

Второй метод - внутреннее (закрытое) хеширование (открытая адресация). Оно, состоит в том, чтобы полностью отказаться от ссылок. В этом случае, если ячейка с вычисленным индексом занята, то можно просто просматривать следующие записи таблицы по порядку (с шагом 1), до тех пор, пока не будет найден ключ K или пустая позиция в таблице.

9. В каком случае поиск в хеш-таблицах становится неэффективен?

Поиск в хеш-таблицах становится менее эффективен, если наблюдается большое число коллизий. Тогда вместо ожидаемой сложности $O(1)$ получим сложность $O(n)$.

В первом методе - поиск в списке осуществляется простым перебором,

так как при грамотном выборе хеш-функции любой из списков оказывается достаточно коротким.

Во втором методе – необходимо просматривать все ячейки, если есть много коллизий.

10. Эффективность поиска в AVL деревьях, в дереве двоичного поиска и в хеш-таблицах

Хеш-таблица - от $O(1)$ до $O(n)$

AVL-дерево - $O(\log_2 n)$

Дерево двоичного поиска – от $O(\log_2 n)$ до $O(n)$.